

1

各位老师好，今天我要分享的内容呢，是智能体在肿瘤学中的应用现状和未来方向。我想从一个很实际的问题开始，各位老师可以回想一下，当一个肿瘤病例进入MDT前呢，医生花时间最多的往往不是说直接下结论，而是要综合病理、影像、病史这些比较多元化的信息，把它们给串起来。所以我们今天要讨论的重点，就是agent能不能承担这部分证据整理的的工作呢？

2

首先呢，我们要建立一个概念，什么是Agent。大模型large language models, 这个大家都知道，那最纯粹的单模态大模型呢，它就是处理一个文本生成的任务，比方可以生成一些小说呀，稿件呀。进一步，如果在大模型生成的过程中呢，人与大模型进行频繁的交互，那这种形式呢，我们就叫它是chatbot。像大家平常使用的豆包啊，这些个都可以是Chatbot的一种形式。然后我们再进一步，对于一些个比较复杂的任务，我们怎么让大模型去处理呢？这个时候呢，我们就需要大模型具有一些额外的能力，比方任务拆解、工具调用、反思规划等。那像这种通过任务编排去解决复杂问题的形式，我们就叫它Agent。另外，对于医学场景呢，我们可能更多的关注证据约束与人工复核。

3

那么谈到医学场景，我们首先要说清楚的是，医学Agent它的应用条件是什么？或者说约束是什么？下面是一个简单的流程，对于一个临床问题，我们一般是先证据检索，再工具核验等等，最后由医生进行一个复核，所以说，既然Agent要进医学场景，那么它的应用条件或约束一定是先检索，再生成，先引用，再解释，最后由医生进行复核。它可以帮助整理病例和证据，但不应该直接输出诊断或治疗决策，有了这个边界的概念呢，我们才谈得上哪些场景适合落地

第4页 | 肿瘤学难点

那么有了前面这个边界以后呢，我们再回到肿瘤学本身。为什么肿瘤学需要 Agent？因为一个看起来很简单的临床问题，它背后往往对应着一条非常复杂的证据链。

比方说，我们既要了解患者的诊断、分期、既往治疗和毒性，又要看最新的指南和研究；同时还要结合影像、病理以及分子检测结果，必要的时候还要进一步寻找临床试验。

而且这些信息并不是分开来看的，它们之间需要相互印证。比如影像提示进展，病理和分子结果是否支持？这些都需要进一步判断。

所以说，Agent在这里真正的价值，不是直接回答“下一步用什么药”，而是把这些分散的信息进行整合、溯源和复核，最终形成一条医生可以追踪、可以核验的证据链。

第5页 | 肿瘤学 Agent 应用方向图谱

那么按照前面所讲的安全边界，我们再来看，目前肿瘤学中的哪些场景更适合 Agent 落地。

这张图的纵轴代表证据所处的阶段；横轴代表这个任务距离真实治疗决策的风险，越往右，风险越高。

可以看到，指南和证据检索距离治疗决策比较远，风险相对较低；临床试验匹配的任务比较标准化，目前的研究证据也相对扎实，所以是近期比较值得关注的應用。MDT会前准备也比较适合人机协同。

而分子报告解释和多模态肿瘤学虽然潜力很大，但是它们更接近临床决策，因此需要更严格的护栏。

第6页 | 现有研究的三点启示

如果把现有研究压缩一下呢，我认为主要可以得到三点启示。

第一，单独使用一个裸 LLM，直接让它回答临床决策问题，目前还不够稳定。模型可能给出一个看起来非常合理的答案，但是其中的证据来源、适用人群，甚至引用本身，都可能存在问题。

第二，加入检索和工具调用以后，答案会更容易核验。这里不仅是让模型“知道得更多”，更重要的是让我们能够看到它查了什么、引用了什么，以及结论是怎么来的。

第三，与其追求一个什么都会的全能模型，不如把复杂任务拆成若干个可以检查的小任务。比如先提取患者信息，再检索证据，再判断适用性，最后交给医生复核。

所以说，接下来我们讨论的重点，不是“AI能不能替代医生”，而是它能不能嵌入一个可追踪、可复核的肿瘤学 workflow。下面我们分别看五个应用场景。

第7页 | 场景一：指南与证据检索

第一个场景呢，是指南和证据检索，这也是风险相对较低的一个应用。

比方说，我们提出一个临床问题：晚期 NSCLC 一线治疗中，免疫联合化疗有哪些生存获益证据？Agent 可以把这个问题拆解以后，分别检索指南、PubMed、药品标签和相关知识库，再把结果整理成一个 Evidence Brief。

这个简报不只是给出一个结论，还要同时说明证据是什么、适用于哪些人群，以及存在哪些 Caveat，也就是限制条件。

这里引用的 Almanac 研究中，大约91%的引用被评估为可信。但是这个数字需要正确理解：它来自314个临床问题和9个专科，评价的是引用可信度，并不是肿瘤专病研究，也没有证明患者结局得到改善。

所以说，RAG的意义是让答案更容易追溯，但并不代表答案一定正确。医生仍然需要判断这些证据是否真正适用于当前患者。

第8页 | 场景二：临床试验匹配

第二个场景是临床试验匹配，我认为这是目前证据相对比较扎实的应用之一。

它的基本流程是，首先提取患者的年龄、肿瘤类型、分期、分子特征和既往治疗；然后从数据库中检索候选试验；再逐条判断入组和排除标准；最后给出排序、匹配理由以及需要人工确认的信息。

TrialGPT的研究中，使用了183个合成患者。它通过不到全部试验6%的候选集合，召回了超过90%的相关试验。对于标准级别的判断，在53个患者、1015个患者与标准的配对中，准确率是87.3%。

在一个小规模用户研究中，两名专家评估36个患者与试验的配对，使用系统以后筛选时间下降了42.6%。这里需要强调，42.6%指的是时间减少，不是患者获益。

另外，TrialMatchAI在52例真实转移性肿瘤患者中，有92%的患者可以在Top-20结果里至少找到一个相关试验。但是这也不能解释成入组准确率。

所以说，这类Agent最适合做的是缩小筛选范围和解释入排标准，最终能不能入组，仍然需要研究团队人工审核。

第9页 | 场景三：精准医学与分子报告解释

第三个场景是精准医学和分子报告解释。这个场景的价值很高，但是风险也会明显增加。

对于一份分子报告，Agent可以识别其中的基因变异，再去检索 OncoKB、指南、PubMed以及 ClinicalTrials.gov，并且整理OncoKB level、ESCAT tier、指南适用性和试验线索。

但是这里特别需要避免一件事情，就是把“证据解释”直接变成“自动推荐用药”。

Benary在2023年的研究中，使用了10个虚构的晚期肿瘤病例和当时版本的4个 LLM。单个模型与专家治疗选项的一致性F1只有0.04到0.19；即使把4个模型合并，F1也只有0.29。另外，一个模型生成的85个唯一NCT编号中，有27个实际上并不存在。

当然，这些是2023年的旧模型，不能直接代表2026年模型的能力。但它很好地提醒我们，引用幻觉和模型版本不稳定是真实存在的风险。

因此，这个场景比较合理的定位，是帮助医生解释证据等级、适用条件和不确定性，而不是由模型自动开出处方。

第10页 | 场景四：MDT 会前证据整合

第四个场景呢，是MDT会前证据整合，这也是我认为比较符合临床实际需求的方向。

在MDT开始以前，Agent可以先完成五方面的整理：第一是病例摘要；第二是缺失信息；第三是指南和关键研究的证据摘要；第四是可能相关的临床试验线索；第五是生成需要在MDT上讨论的问题清单。

这样做的目的，不是提前替MDT作出结论，而是让参会专家能够更快地进入真正需要判断的问题。

这里展示的RCC研究是一个单中心回顾性研究，一共纳入103例患者。AI结果与MDT的一致率是62.1%， κ 值是0.44。

这个数字同样需要谨慎解释。一致率并不等于正确率，而且“用于会前准备”是我们基于安全边界作出的应用转译，并不是原研究已经验证的临床终点。

所以说，这里输出的是会前讨论材料，而不是MDT决议。最终的判断仍然属于临床专家团队。

第11页 | 场景五：多模态肿瘤学

第五个场景是多模态肿瘤学。所谓多模态，就是一个病例中不只有文本，还包括影像、病理、基因组以及指南等多种类型的证据。

在这个工作流中，Agent更像一个协调器。它根据任务选择不同工具，再把影像证据、病理证据、基因组证据和指南证据组织到同一条证据链中，最后交给专家检查证据适用性、风险和冲突。

Nature Cancer的相关研究使用了20个现实感病例。其中，64次所需工具调用成功了56次，也就是87.5%。在245个可以评价的陈述中，有223个事实正确，对应91.0%。

但是不能只看91%这个数字。其中仍然有16个错误陈述和6个潜在有害陈述。同时，257条引用中有194条与陈述相符，也就是75.5%，另外还存在无关引用和冲突引用。

所以说，这里的91%是陈述级事实正确率，不是患者层面的诊疗准确率。多模态Agent确实有潜力，但目前更多还是早期系统评价，尚未证明能够改善真实临床结局。

第12页 | Demo 简介

那么讲完这五个场景以后呢，下面我用一个简单的Demo，把MDT会前准备这个场景进一步具体化。

这个Demo叫作Onco-MDT Evidence Brief。它不是一个自动问诊系统，也不会直接给出治疗医嘱。它主要完成的是，把一个模拟病例转化成可以供MDT讨论的证据简报。

这里输入的是一个去身份化的模拟黑色素瘤病例，包括疾病分期、既往治疗、BRAF状态以及当前MDT最关心的问题。

系统输出的内容包括病例摘要、MDT关键问题、证据摘要、临床试验预筛线索、缺失信息和不确定性，以及最终需要医生复核的位置。

整个演示有三条底线：不使用真实患者数据，不输出治疗医嘱，所有结果都必须经过人工复核。

第13页 | Evidence Brief 工作流

这一页展示的是这个Demo背后的完整流程。

首先输入模拟病例，然后由Agent进行问题拆解。问题拆解以后，我们设置了第一个人工确认点，由医生确认模型理解的问题是不是我们真正要检索的问题。

确认以后，系统再进行证据检索和工具核验，生成Evidence Brief。在导出以前，还要经过第二个人工复核点，检查证据来源、适用范围以及模型有没有超出证据边界。

所以说，这个流程的重点并不是自动生成一份看起来很漂亮的文字，而是把人工确认和风险控制嵌入到每一个关键节点。

最后输出的是一个可以编辑、可以追溯、可以继续讨论的证据简报，而不是一个自动生成的治疗方案。

第14页 | 总结

那么回到整场汇报，我想用三句话做一个总结。

第一，肿瘤学Agent的价值在于证据整合，而不是替代医生。它最适合承担的是信息量大、重复性高，但是仍然需要专业判断的准备工作。

第二，它的优势在于建立一个可以追踪的流程，而不是给出一次看起来很聪明的回答。我们需要知道它检索了什么、引用了什么，以及哪些信息仍然缺失。

第三，它的安全边界是由证据适用性、不确定性和人工复核共同决定的。并不是自动化程度越高越好，而是整个过程越透明、越容易复核，才越有可能进入临床。

所以说，一个比较稳妥的工作流应该是：从临床问题出发，完成来源检索和证据适用性判断，最后由医生复核，并形成可审计的Evidence Brief。

第15页 | 未来展望

最后我们再来看，肿瘤学Agent要真正从研究原型走向临床，还需要解决三个问题。

第一个是前瞻性的获益与安全性。未来不能只看模型在测试集上的准确率，而要把它放进真实工作流，评价它能不能节省时间、提高信息质量，同时不增加临床风险。

第二个是多中心验证和亚组公平性。一个系统在一家医院表现良好，并不代表换一个中心、换一套设备或者换一个患者人群以后仍然有效。

第三个是版本、漂移和责任治理。模型、提示词、工具和知识库都在不断更新，因此每一次输出使用了什么版本、出现问题由谁负责，都需要被记录和审计。

所以说，临床转化的标准并不是“更多模态、更多Agent”，而是能不能做到前瞻性验证、多中心泛化和全流程治理。

只有当这个系统真正做到可验证、可追踪、可复核，我们才谈得上让Agent进入肿瘤临床。

我的汇报到这里，谢谢各位老师。